HTWG KONSTANZ • UBIQUITOUS COMPUTING LAB • AIN SEMESTER 7 (WS 2026/27)

Teamprojekt: Modell-Vergleich für Schlafapnoe-Klassifikation

Aufgabenverteilung & 3-Folien-Präsentationsleitfaden für die Teammitglieder

Fokus: 100% Polysomnographie (PSG) & Obstructive Sleep Apnea (OSA)

Format: Genau 3 Folien pro Person (3–5 Min. Pitch)

Ziel: Methodisches Fundament für KES-Paper & Software-Architektur

Zweck & Spielregeln für unser nächstes Team-Meeting

Jedes Teammitglied erarbeitet eigenständig **eines der 5 Schwerpunktthemen** anhand des zugeteilten Papers. Alle 5 Paper basieren vollständig auf **Polysomnographie-Daten (PSG)** (z. B. SHHS, MESA, Apnea-ECG, UCDDB) und konzentrieren sich direkt auf **Schlafapnoe-Erkennung**.

Einheitlicher 3-Folien-Standard: Folie 1: *Architektur & PSG-Datenfluss* • Folie 2: *Schwerpunktthema* • Folie 3: *Bewertung & Vor-/Nachteile fürs Projekt*.

Task 1: Die Labor-Baseline & Grad-CAM (1D-CNN)

Zuständig: Teammitglied 1 • Fokus: End-to-End 1D-Faltungsnetze & gradientenbasierte Erklärbarkeit

1D-CNN BASELINE

Zugehöriges Paper: Á. Serrano Alarcón, R. Seepold et al. (2023): *Obstructive sleep apnea event detection using explainable deep learning models for a portable monitor.* Frontiers in Neuroscience.
PSG-Datensätze: SHHS1, SHHS2 & MESA (Voll-Polysomnographie) • **PSG-Sensoren:** SpO2, Puls/HR, Thorax- & Abdomen-Atmungsgurte (1 Hz, 60s)
Quellen: Lokal im Ordner `docs/Papers/` • Direktes PDF (PMC10157077) • Frontiers Volltext

ERWARTETES 3-FOLIEN-ERGEBNIS:

Folie 1: Architektur & Datenfluss

- 4 parallele Biosignalkanäle auf 1 Hz herabgetaktet im 60s-Fenster (4×60 Tensor).
- 1D-Faltungsschichten zur Merkmalsextraktion + Global Average Pooling (GAP) anstelle dichter Fully-Connected-Schichten.

Folie 2: XAI-Schwerpunkt – Wie rechnet Grad-CAM?

- Mathematisches Prinzip: Rückrechnung der Gradienten der Apnoe-Klasse auf die letzte Faltungsschicht.
- Visuelles Ergebnis: Farbige Heatmap direkt über dem Signalverlauf zeigt, welche Sekunden die Apnoe indizieren.

Folie 3: Bewertung & bekannte Schwächen fürs Teamprojekt

- *Vorteile:* Labor-Referenz von Prof. Seepold (Pflicht-Vergleichswert); extrem schnell (<5 ms Inferenz auf Laptop-CPU).
- *Limitierungen:* AHI wird überschätzt (nutzt Gesamtaufzeichnung TRT statt reiner Schlafzeit TST); Informationsverlust durch 1 Hz; isolierte Fenster ohne Zeitkontext.

Kernfrage fürs Meeting: Warum ist dieses Modell unsere Pflicht-Baseline, und an welchen konkreten Stellen (z. B. TST-Berechnung, höhere Frequenzen) müssen wir es zwingend verbessern?

Task 2: Klassisches Machine Learning (Feature Engineering + Random Forest)

CLASSICAL ML

Zuständig: Teammitglied 2 • Fokus: Handgefertigte Kennzahlen & tabellarische Klassifikatoren vs. Deep Learning

Zugehöriges Paper: J. Zhu, A. Zhou, Q. Gong et al. (2022): *Detection of Sleep Apnea from Electrocardiogram and Pulse Oximetry Signals Using Random Forest.* Applied Sciences (MDPI).
PSG-Datensatz: Apnea-ECG Database (PhysioNet overnight PSG) • **PSG-Sensoren:** EKG & SpO2 (Pulse Oximetry)
Quellen: Direktes PDF (MDPI) • MDPI Webversion • PMC9103632

ERWARTETES 3-FOLIEN-ERGEBNIS:

Folie 1: Der klassische zweistufige ML-Workflow auf PSG-Daten

- Gegenüberstellung: Menschliches Expertenwissen (Feature Engineering) vs. automatische Merkmalsfindung (Deep Learning).
- Pipeline: PSG-Rohdaten → Feature Extraction → Feature Selection (RFECV) → Random Forest / SVM.

Folie 2: Welche PSG-Kennzahlen entscheiden über Apnoe?

- EKG-HRV-Kennzahlen im Zeitbereich (SDNN, RMSSD) und Frequenzbereich (LF/HF-Ratio, spektrale Leistungsdichte).
- SpO2-Entsättigungsmerkmale (Oxygen Desaturation Index ODI, min/max SpO2-Dips, Varianz).
- Wie RFECV (Recursive Feature Elimination) die 15–20 aussagekräftigsten Features isoliert.

Folie 3: Bewertung fürs Teamprojekt & KES-Paper

- *Vorteile:* Trainiert in Sekunden auf CPU; 97,5 % Accuracy; volle Akzeptanz bei Ärzten (Features sind Standard-Diagnostik); Feature-Importance (Gini/SHAP).
- *Nachteile:* Findet keine neuen Muster abseits der Formeln; anfällig für Rauschen/Artefakte; hoher manueller Vorbereitungsaufwand.

Kernfrage fürs Meeting: Sollen wir Random Forest als leichtgewichtige Vergleichs-Baseline in unserer Software und im KES-Paper mitlaufen lassen?

Task 3: Sequentieller Kontext & Zeitdynamik (Hybrid CNN-LSTM)

HYBRID CRNN

Zuständig: Teammitglied 3 • Fokus: Physiologische Zeitverzögerungen & Gedächtnis über mehrere Minuten

Zugehöriges Paper: B. Wang, X. Deng et al. (2021): *Automatic Detection of Obstructive Sleep Apnea Events Using a Deep CNN-LSTM Model.* Computational Intelligence and Neuroscience.
PSG-Datensatz: Apnea-ECG Polysomnographie (PhysioNet) • **PSG-Sensoren:** EKG-Zeitserien & Atmungsreaktionen aus der PSG
Quellen: Direktes PDF (PMC8009718) • PMC Webversion

ERWARTETES 3-FOLIEN-ERGEBNIS:

Folie 1: Die hybride CNN-LSTM Architektur (CRNN)

- Multi-Scale 1D-CNN extrahiert lokale Kurvenmorphologien im aktuellen Zeitfenster.
- Nachgeschaltetes LSTM verarbeitet die Merkmalsvektoren sequentiell und lernt Abhängigkeiten zwischen aufeinanderfolgenden Minuten.

Folie 2: Warum braucht Apnoe-Erkennung ein zeitliches Gedächtnis?

- Physiologische Verzögerung: Sauerstoffabfall (SpO2) tritt erst **15–30 Sekunden nach** dem Atemstillstand auf; danach folgt Aufwach-Tachykardie.
- Isolierte CNN-Fenster übersehen diese Kettenreaktion; das LSTM glättet unruhiges „Flackern" der Erkennung zwischen den Minuten.

Folie 3: Bewertung fürs Teamprojekt & Software

- *Vorteile:* Decken von zeitlich versetzten Ereignissen; realistischere Abbildung der Schlafpathologie; hohe Sensitivität (96,1 %).
- *Nachteile:* Längeres Training (schwerer parallelisierbar); XAI wird komplexer (LSTM ist eine Black-Box, Grad-CAM läuft nur auf CNN-Teil).

Kernfrage fürs Meeting: Rechtfertigt der Genauigkeitsgewinn durch das Zeitgedächtnis (LSTM) den höheren Trainings- und Erklärungsaufwand gegenüber reinen 1D-CNNs?

Task 4: PSG-Sensorstrategie: Einheitsmodell vs. Modell pro Sensortyp

Zuständig: Teammitglied 4 • Fokus: Early Fusion (Alarcón 4-Kanal) vs. Late/Decision Fusion bei PSG-Sensorausfall

SENSOR FUSION

Paper 1 (Praxis): Á. Serrano Alarcón et al. (2023) – 4-Kanal PSG-Einheitsmodell (liegt in `docs/Papers/`)
Paper 2 (Theorie): M. Salvi et al. (2024): *Multi-modality approaches for medical support systems.* Information Fusion (liegt in `docs/Papers/`)
PSG-Sensoren: SpO2, EKG/HR, Thorax- & Abdomen-Atmungsgurte • **Quellen:** Salvi et al. ScienceDirect • Alarcón et al. PDF

ERWARTETES 3-FOLIEN-ERGEBNIS:

Folie 1: Gegenüberstellung der beiden Fusions-Paradigmen

- *Early Fusion (Alarcón et al.):* 4 PSG-Sensorkanäle werden in einen gemeinsamen Tensor (4×60) geklebt und durch 1 einziges Netz geschleust.
- *Late / Decision Fusion (Salvi et al.):* Modell 1 (SpO2-Spezialist) + Modell 2 (Puls-Spezialist) + Modell 3 (Atmungs-Spezialist) stimmen am Ende ab.

Folie 2: Der PSG-Stresstest (Sensorausfall & Abtastraten)

- *Abtastraten-Problem:* Alarcón muss alles auf 1 Hz heruntersamplen (verliert feine EKG-Details); getrennte Modelle erlauben native Abtastraten (z. B. 250 Hz EKG).
- *Sensorausfall:* Was passiert, wenn der SpO2-Fingerclip nachts abrutscht? (Einheitsmodell scheitert komplett; Decision Fusion ignoriert SpO2 und läuft mit Atmung weiter).

Folie 3: Empfehlung für unsere Software-Architektur

- Gegenüberstellung: Kompaktes Einheitsmodell (schnell trainiert) vs. modularer Multimodell-Ansatz (extrem robust & transparent im Dashboard).
- Fazit: Wie flexibel muss unsere GUI auf unvollständige PSG-Aufzeichnungen reagieren können?

Kernfrage fürs Meeting: Setzen wir auf ein starres 4-Kanal-Netzwerk oder auf eine modulare Architektur, die auch bei Ausfall eines Sensors eine Diagnose liefert?

Task 5: Multimodaler PSG-Transformer & Cross-Attention

Zuständig: Teammitglied 5 • Fokus: Multi-Scale Transformer, dynamische Signal-Interaktion & AHI-Schweregrad

SOTA TRANSFORMER

Zugehöriges Paper: Y. Zhang, L. Zhou, S. Zhu et al. (Januar 2025): *Deep Learning for Obstructive Sleep Apnea Detection and Severity Assessment: A Multimodal Signals Fusion Multiscale Transformer Model.* Nature and Science of Sleep.
PSG-Datensätze: 510 klinische PSG-Patienten + Apnea-ECG + UCDDB (University College Dublin Sleep Apnea Database)
PSG-Sensoren: EKG & SpO2 • **Quellen:** Direktes PDF (PMC11736780) • PMC Webversion

ERWARTETES 3-FOLIEN-ERGEBNIS:

Folie 1: Die Multiscale Transformer Architektur

- Getrennte Vorverarbeitung für EKG und SpO2 → Einspeisung in **Cross-Modal Interaction Blocks** (Signal A gewichtet Signal B).
- Multi-Scale Transformer fängt sowohl kurze Sekunden-Anomalien als auch übergeordnete Trends über die Nacht ein.

Folie 2: AHI-Schweregrad & Attention-Erklärbarkeit

- Bestimmt nicht nur Apnoe-Episoden, sondern berechnet direkt den klinischen AHI-Schweregrad (leicht, mittel, schwer) mit über 96 % Zuverlässigkeit.
- Intrinsische Erklärbarkeit: Attention-Heatmaps zeigen dem Arzt live, wie stark sich das Modell auf SpO2 vs. EKG gestützt hat.

Folie 3: Bewertung fürs Teamprojekt & KES-Paper

- *Stärken:* Modernste SOTA-Referenz (2025) direkt für Schlafapnoe auf PSG; perfekte methodische Antwort auf unsere Kernfrage (multimodale Fusion).
- *Hürden:* Anspruchsvoller in PyTorch umzusetzen; höherer Hyperparameter- und Regularisierungsbedarf gegen Overfitting.

Kernfrage fürs Meeting: Bietet uns dieser SOTA-Transformer genug Innovationsvorteil im KES-Paper, um den höheren Programmieraufwand im Team zu rechtfertigen?

Zusammenfassung: Wie alles im Meeting zusammenläuft

Task	Modell-Typ	Zentrale Frage für unser Projekt	Hauptrolle im KES-Paper
Task 1	1D-CNN (Alarcón)	Reichen isolierte Fenster & 1-Hz-Sampling?	Die unumgängliche Labor-Baseline von Prof. Seepold
Task 2	Random Forest (Zhu)	Brauchen wir überhaupt Deep Learning?	Der transparente, klassische Benchmark (Explainability)
Task 3	CNN-LSTM (Wang)	Löst Zeitgedächtnis das SpO2-Verzögerungsproblem?	Der Nachweis für den Nutzen temporaler Dynamik
Task 4	Early vs. Late Fusion (Salvi/Alarcón)	Was passiert in der Praxis bei Sensorausfall?	Die Begründung für unsere Software-Architektur
Task 5	Cross-Attention Transformer (Zhang)	Wie nutzen wir Multimodalität maximal aus?	Der State-of-the-Art Innovationsbeitrag unseres Papers